


PROYECTO CODERQATAR

Mundial 2022



Michael Hans Evans
Dni:37106928

Introducción:

La Copa Mundial de la FIFA, también conocida como Copa del Mundo, es el principal torneo internacional oficial de fútbol masculino a nivel de selecciones nacionales en el mundo.

Este evento deportivo se realiza cada cuatro años desde 1930. El mismo cuenta con dos etapas principales: un proceso clasificatorio en el que participan más de 200 selecciones nacionales y una fase final realizada cada cuatro años en una sede definida con anticipación en la que participarán 32 equipos, durante un periodo cercano a un mes.

La fase final del torneo es el evento deportivo de una sola disciplina más importante del mundo y el segundo más importante a nivel general después de los Juegos Olímpicos.

Se realizó en 22 ocasiones, en las que ocho países, considerados históricamente potencias mundiales, han ganado la copa, en los cuales se encuentra Brasil con cinco victorias; Alemania e Italia le siguen con cuatro trofeos; Argentina con tres; Uruguay y Francia la han ganado dos veces, en tanto Inglaterra y España se han titulado campeones una vez.

Descripción de la temática de los datos:

Como es de público conocimiento la Copa del mundo de la FIFA Qatar es un evento que se realizó en el año 2022, en el mismo participaron 32 países y se disputaron 64 partidos, el mismo arrojó como vencedor a Argentina.

Para el presente proyecto se extrajeron datos de dicha competencia. Esta información nos proporciona los datos relacionados con todos los partidos jugados en el torneo desde el primer partido hasta la final, incluido el partido por el tercer puesto.

En total tenemos datos completos de 64 partidos que transcurrieron desde 20 de noviembre de 2022 y concluyeron el día de la final el 18 de diciembre de 2022.

Estos datos se recompilan a partir de los datos disponibles gratuitamente con algunos campos adicionales agregados por web scrapping.

Hipótesis

En nuestro análisis intentaremos comprender como se comportaron las estadísticas de los equipos durante el desarrollo de la competencia ya sean los goles que realizaron de donde se realizaron además de los intentos que llevo realizar dichos goles, la posesión de balón, pases realizados y cuantos fueron con éxitos, entre otras. A partir de estos datos nosotros intuimos que los equipos que fueron avanzando durante la competencia fueron los que mejor se posicionaron en base a las estadísticas recopiladas o tuvieron mas de la mitad de los ítems más favorables que sus contrincantes.

Sumado a esto nos interesa ver como se desempeñaron los árbitros en el correr de la competencia en cuanto a su accionar con las tarjetas ya sean amarillas y rojas frente a las faltas cometidas y si se comportaron todos de una manera similar. Suponiendo que se sacaron un 50% o menos de tarjetas amarillas en cuanto a faltas y un 5% o menos de rojas.

Por último, se genera una intriga que cantidad de espectadores concurrieron a los eventos y si dicho numero fue constante durante el correr de la competencia o si fue disminuyendo, teniendo en cuenta que la cantidad de partidos disminuye en el transcurso de esta.

Herramientas tecnológicas implementadas

Para el presente trabajo se utilizaron los siguientes programas:

- Excel para la lectura y limpieza de los datasets.
- Miro para la creación del diagrama entidad-relación (<https://miro.com/>).
- Power BI Desktop para la creación del tablero de control.


Datasets

Partiendo del dataset de descargamos a través del proceso de normalización, dividimos estos datos en ocho tablas diferentes, para poder general las relaciones necesarias y tener un buen manejo de la información que poseen.

Por tal motivo, su información fue reorganizada de la siguiente manera:

Dataset Original:

Al descargar el *dataset*, los datos se encontraban como se puede observar en la siguiente imagen:



Dada la forma en que se encontraban los datos decidimos realizar algunas modificaciones

- 1) El primer paso que se realizó fue dividir los datos en columnas, con la opción “Texto en columna”, además se le colocó el formato correspondiente a cada columna como por ejemplo la fecha que se jugó el partido (la misma era “mmddyyyy”)
- 2) Luego de esto se nos presentó un reto dado que se contaba con 64 filas y 59 columnas, en cada fila se encontraban los datos de cada partido (Lo que incluía las estadísticas de dos equipos por fila), esto no nos permitía relacionar bien las estadísticas de cada equipo, por lo que se procede a generar la “Tabla Estadísticas”.

Esta tabla está compuesta por las diferentes estadísticas de cada país por partido que disputo durante la competencia, agrupando las columnas de esta índole.

Para poder lograr esto se debió separa en filas distintas las estadísticas de cada equipo por cada partido jugado, es decir que las estadísticas completas de un partido van a estar distribuidas en dos filas una para cada equipo. Agrupando las columnas de esta índole en dicha tabla.

Para esto se generaron 128 filas, a las cuales se creo una clave para distinguir cada partido, y además una clave primaria para distinguir cada fila, la cual se formo concatenando dos columnas el id de cada país(se detalla más adelante) y el id de cada partido.


[illegible]

- 3) Mas a delante lo que hicimos fue crear una nueva tabla en el cual remplazamos los nombres de cada país y les asignamos una "id", esto nos permitió se mas eficientes y no tener una redundancia de datos .

País

En la siguiente tabla se muestran los países que participaron en la competencia y el grupo al que pertenece cada uno.

Para lograr esta tabla solo reemplazamos el nombre de cada país por el id en la tabla estadística, además de crear una nueva columna en la cual especificamos a que grupo pertenecía cada país .




The screenshot shows an Excel spreadsheet with the following data:

id_Paises	Paises	Grupo_al_que_pertenece
1	ARGENTINA	C
2	AUSTRALIA	D
3	BELGICA	F
4	BRAZIL	G
5	CAMERUN	G
6	CANADA	F
7	COSTA RICA	E
8	CROACIA	F
9	DINAMARCA	D
10	ECUADOR	A
11	INGLATERRA	B
12	FRANCIA	D
13	ALEMANIA	E
14	GHANA	H
15	IRAN	B
16	JAPON	E
17	SUR KOREA	H
18	MEXICO	C
19	MARRUECOS	F
20	PAISES BAJOS	A
21	POLONIA	C
22	PORTUGAL	H
23	QATAR	A
24	ARABIA SAUD	C
25	SENEGAL	A
26	SERBIA	E
27	ESPAÑA	E
28	SUIZA	G

- 4) Luego juntamos todas las columnas que hacían referencia a el partido y creamos la tabla partidos asignándole un “id” a cada uno de los 64 partidos jugados

Partidos:

Esta tabla nos muestra la información sobre la fecha y hora el número de partido y los espectadores que concurrieron a ver el evento.



The screenshot shows an Excel spreadsheet with the following data:

id_Partido	id_Dia_del_partido	Fecha	Hora	Espectadores
1,00 7		20/11/2022	17:00:00	67372
2,00 1		21/11/2022	14:00:00	45334
3,00 1		21/11/2022	17:00:00	41721
4,00 1		21/11/2022	20:00:00	43418
5,00 2		22/11/2022	11:00:00	88012
6,00 2		22/11/2022	14:00:00	42925
7,00 2		22/11/2022	17:00:00	39369
8,00 2		22/11/2022	20:00:00	40875
9,00 3		23/11/2022	11:00:00	59407
10,00 3		23/11/2022	14:00:00	42608
11,00 3		23/11/2022	17:00:00	40013
12,00 3		23/11/2022	20:00:00	40432
13,00 4		24/11/2022	11:00:00	39089
14,00 4		24/11/2022	14:00:00	41663
15,00 4		24/11/2022	17:00:00	42662
16,00 4		24/11/2022	20:00:00	88103
17,00 5		25/11/2022	11:00:00	40875
18,00 5		25/11/2022	14:00:00	41797
19,00 5		25/11/2022	17:00:00	44833
20,00 5		25/11/2022	20:00:00	68463
21,00 6		26/11/2022	11:00:00	41823
22,00 6		26/11/2022	14:00:00	44259
23,00 6		26/11/2022	17:00:00	42860
24,00 6		26/11/2022	20:00:00	88966
25,00 7		27/11/2022	11:00:00	41479
26,00 7		27/11/2022	14:00:00	43738
27,00 7		27/11/2022	17:00:00	44374
28,00 7		27/11/2022	20:00:00	68895

- 5) Al crear la tabla partido observamos que se podía llegar a un nivel mas de normalización de los datos por lo que se crea la tabla día del partido

Día del Partido

La siguiente tabla muestra el día de la semana en que transcurrió la competencia.

Se creo un tabla en la cual se genero un id para cada día de la semana y se lo reemplazo por el día en que se jugaba cada partido .

id_Dia_del_pt	Dia del partido
1	Lunes
2	Martes
3	Miércoles
4	Jueves
5	Viernes
6	Sábado
7	Domingo

- 6) Luego notamos que se repetían los mismos estadios en cada fila por lo que decidimos crear una tabla nueva para los estadios y crear una id para cada uno de ellos y reemplazarlos

Estadios:


La siguiente tabla muestra los estadios en los cuales se llevó a cabo la competencia.

id_Estadio	Estadio
1	Ahmed bin Ali Stadium
2	Al Bayt Stadium
3	Al Janoub Stadium
4	Al Thumama Stadium
5	Education City Stadium
6	Khalifa International Stadium
7	Lusail Iconic Stadium
8	Stadium 974

- 7) Para los árbitros tuvimos un proceder similar al de los estadios realizando el mismo procedimiento de crear una tabla y generar id para cada arbitro

Arbitro

La información que contiene la siguiente tabla muestra el árbitro encargado de dirigir el encuentro.




The screenshot shows an Excel spreadsheet with a table of referees. The table has two columns: 'id_Arbitro' and 'Arbitro'. The data is as follows:

id_Arbitro	Arbitro
1	Abdulahman Ibrahim Al Jassim
2	Alireza Faghani
3	Andrés Matonte
4	Anthony Taylor
5	Antonio Mateu Lahoz
6	Bakary Papa Gassama
7	Cesar Ramos
8	Chris Beath
9	Clement Turpin
10	Daniel Siebert
11	Daniele Orsato
12	Danny Makkelie
13	Facundo Tello
14	Fernando Rapallini
15	Ismail Elfath
16	Ivan Barton
17	Janny Sikazwe
18	Jesús Valenzuela Sáez
19	Mario Escobar
20	Matt Conger
21	Michael Oliver
22	Mohammed Abdulla Hassan
23	Mustapha Ghorbal
24	Raphael Claus
25	Slavko Vincic
26	Stephanie Frappart
27	Szymon Marciniak
28	Victor Gomes

- 8) Cuando observamos las etapas de la competencia vimos que teníamos un inconveniente ya que en la fase de grupo la misma se identificaba por el grupo al que pertenecía cada país (ejemplo grupo a ,b) por lo que reemplazamos estos datos por “fase de grupo” ya que el grupo al que pertenecen esta especificado en la tabla país.

Etapas de la competencia:

En la tabla siguiente muestra las etapas de la competencia, desde las fases de grupo hasta la final. Se creo la tabla se le asigno un id a cada fase y se la reemplazo por la misma.



The screenshot shows an Excel spreadsheet with a table of competition stages. The table has two columns: 'id_Fase_Group' and 'Fases'. The data is as follows:


id_Fase_Group	Fases
1	Final
2	Fase de grupo
3	Tercer Puesto
4	Cuartos de Final
5	Octavos de Final
6	Semi-Final

9) Cuando realizamos estos pasos nos dimos cuenta que no había una buena relación entre algunas tablas ya que se formaba una relación de muchos a muchos lo que no nos permitía segmentar los datos para lo que estaba destinados, por lo que creamos la tabla mundial en la cual se generó una clave primaria a partir del id de cada partido y el id de cada país, esto nos permitió generar relaciones de uno a muchos y de uno a uno.

Mundial:

Esta tabla conecta las demás tablas a través de sus correspondientes claves primarias (PK) y/o sus llaves foráneas (FK).

En esta tabla se insertaron las claves primarias de otras tablas (Etapas de la competencia, Estadio entre otras), y se generó una FK que mejoró las relaciones del diagrama.



	A	B	C	D	E	F	G	H	I	J	K	L	M	N
	id_Partido_Equipo	id_Partido	id_Estadio	id_Arbitro	id_Fase_Grupo	id_Equipos								
1	12375	1,00		2 11	2,00	23,00								
2	211	2,00		6 24	2,00	11,00								
3	325	3,00		4 29	2,00	25,00								
4	430	4,00		1 1	2,00	30,00								
5	51	5,00		7 25	2,00	1,00								
6	69	6,00		5 7	2,00	9,00								
7	718	7,00		8 8	2,00	18,00								
8	812	8,00		3 28	2,00	12,00								
9	919	9,00		2 14	2,00	19,00								
10	1013	10,00		6 16	2,00	13,00								
11	1127	11,00		4 22	2,00	27,00								
12	123	12,00		1 17	2,00	3,00								
13	1328	13,00		3 13	2,00	28,00								
14	1431	14,00		5 9	2,00	31,00								
15	1522	15,00		8 15	2,00	22,00								
16	164	16,00		7 2	2,00	4,00								
17	1732	17,00		1 19	2,00	32,00								
18	1823	18,00		4 5	2,00	23,00								
19	1920	19,00		6 23	2,00	20,00								
20	2011	20,00		2 18	2,00	11,00								
21	2129	21,00		3 10	2,00	29,00								
22	2221	22,00		5 29	2,00	21,00								
23	2312	23,00		8 27	2,00	12,00								
24	241	24,00		7 11	2,00	1,00								
25	2516	25,00		1 21	2,00	16,00								
26	263	26,00		4 7	2,00	3,00								
27	278	27,00		6 3	2,00	8,00								
28	2827	28,00		2 12	2,00	27,00								

Base de datos relacionada a Power BI


A continuación, se adjunta el Excel con las bases de datos organizadas y estructuradas utilizadas en el presente trabajo:



✓ ProyectoCoder.
xlsx

Diagrama entidad-relación

A continuación, se detalla el diagrama entidad-relación creado para el proyecto:



Listado de tablas

En este punto realizaremos de cada una de las tablas junto a una pequeña descripción de estas y la definición de la clave primaria y foránea:

Tabla Estadística

En esta tabla se encuentran las estadísticas de cada equipo, los goles que realizaron ,posesión, tiros al arco entre otros, en su mayoría son datos cuantitativos de los equipos.

- PK: id_Estaditica_por_Partido
- FK: id_Partido_Equipo
- FK: id_Equipos

Tablas Estadio

En esta tabla encontraremos los estadios en los cuales se realizó la competencia.

- PK: id_Estadio

Tablas Partidos

En dicha tabla se encuentra información del partido, la fecha en la que se jugó, el numero de espectadores.

- PK: id_Partido
- FK: id_Dia_del_partido

Tablas Dia del Partido

En esta tabla se encuentra los días de la semana con sus respectivos id

- PK: id_Dia_del_partido

Tablas Arbitro

En esta tabla se encuentran los nombres de las personas que se desempeñaron como árbitros durante la competencia

- PK: id_Arbitro

Tablas países

Aquí se encuentra los nombre de los países que participaron en la competencia , y al grupo al cual pertenecían los mismo.

- PK: id_Paises

Tablas Fase de Grupo

La tabla contiene las etapas de la competencia desde la fase de grupo a la misma final

- PK: id_Fase_Grupo

Tabla Mundial

En esta tabla se encuentra la información necesaria para poder realizar relaciones entre las distintas tablas de el diagrama de entidad relación , dicha tabla puente nos permite entablar relaciones de uno a muchos y subsanar las relaciones de muchos a muchos que nos traían algunas complicación a ala hora de relacionar dichas tablas.

- PK: id_Partido_Equipo
- FK: id_Partido
- FK: id_Estadio
- FK: id_Arbitro
- FK: id_Fase_Grupo
- FK: id_Equipos

Medidas

Dicha tabla contiene todas las medidas calculadas creadas.

Listado de columnas por tablas

A continuación, se mencionará las columnas que posee cada tabla junto con su tipo de campo y clave:

Tabla Mundial		
Campo	Tipo de campo	Tipo de clave
id_Partido_Equipo	int	PK
id_Partido	int	FK
id_Estadio	int	FK
id_Arbitro	int	FK
id_Fase_Grupo	int	FK
id_Equipos	int	FK

Tabla Estadística		
Campo	Tipo de campo	Tipo de clave
id_Estaditica_por_Partido	int	PK
id_Partido_Equipo	int	FK
id_Equipos	int	FK
Numero_de_Partido	int	
Probabilidad_cada_tiro_gol	int	
posesión	int	
Gol	int	
Intentos_de_gol_del_equipo	int	
Gol_concedido_al_equipo	int	
Gol_desde_dentro_del_área_penal	int	
Gol_desde_fuera_del_área_penal	int	

Tiros_al_arco_del_equipo	int	
Tiros_desviados	int	
Intentos_desde_dentro_del_área_penal	int	
Intentos_desde_fuera_del_área_penal	int	
Tarjetas_amarillas_del_equipo	int	
Tarjetas_rojas_del_equipo	int	
Falta_contra_el_equipo	int	
Fuera_de_juego	int	
Pases	int	
Pases_Completados	int	
Tiros_de_Esquinas	int	
Tiros_libres	int	
Penales_anotados	int	
Goles_evitado	int	
Gol_en_propia_puerta	int	
Pérdidas_de_balón_forzadas	int	
Presión_defensiva_aplicada	int	

Tablas Estadio		
Campo	Tipo de campo	Tipo de clave
id_Estadio	int	Pk
Estadio	text	

Tablas Partidos		
Campo	Tipo de campo	Tipo de clave
id_Partido	int	
id_Dia_del_partido	int	
Fecha y Hora	datetime	
Expectadores	int	

Tablas Dia del Partido		
Campo	Tipo de campo	Tipo de clave
id_Dia_del_partido	int	PK
Dia_del_partido	text	


Tablas Arbitro		
Campo	Tipo de campo	Tipo de clave
id_Arbitro	int	PK
Arbitro	text	

Tablas Países		
Campo	Tipo de campo	Tipo de clave
id_Paises	int	PK
Países	text	
Grupo_al_que_pertenece	text	

Tablas Fase de Grupo		
Campo	Tipo de campo	Tipo de clave
id_Fase_Grupo	int	PK
Grupos_Fases	text	

Modelo relacional en Power BI

Cuando realizamos la carga del archivo a Power BI las relaciones que teníamos se respetaron ya que coincidían los nombre en ambas tablas, excepción de una en la cual se debió realizar manualmente cambiando el tipo de dato, y colocando la relación manualmente .



Segmentaciones elegidas

La segmentación que utilizamos es:

- Segmentado por País
- Segmentado por Etapa de la competencia
- Grupo al que pertenece el país

Medidas calculadas

Dado la composición de las tablas no fue necesario aplicar gran cantidad de medidas al análisis las cuales fueron colocadas en la tabla de “Medidas”, de igual forma se desarrollaron las siguientes:

- Tiros_al_arco_del_equipo más Tiros_desviados =
`SUM('Estadisticas'[Tiros_al_arco_del_equipo]) +
SUM('Estadisticas'[Tiros_desviados])`
- Total acumulado de Gol en Grupos_Fases =
`CALCULATE(
SUM('Estadisticas'[Gol]),
FILTER(
ALLSELECTED('Etapas de la competencia'[Grupos_Fases]),
ISONORAFTER('Etapas de la competencia'[Grupos_Fases], MAX('Etapas de
la competencia'[Grupos_Fases]), DESC)`
- Total de Tarjetas_amarillas_del_equipo para Numero_de_Partido =
`CALCULATE(
SUM('Estadisticas'[Tarjetas_amarillas_del_equipo]),
ALLSELECTED('Estadisticas'[Numero_de_Partido])`


Total de Tarjetas_rojas_del_equipo para Numero_de_Partido =
`CALCULATE(
SUM('Estadisticas'[Tarjetas_rojas_del_equipo]),
ALLSELECTED('Estadisticas'[Numero_de_Partido])`

Visualización de los datos


1. Presentacion :




2. Estadios



3. País



4.Gol



Conclusión

Después de analizar los datos concluimos que no siempre el equipo que gana es el de las mejores estadísticas (gol, posesión, etc.), pero si damos por sentado que estas influyen en su resultado que cuando mejor son sus estadísticas mas avanzaron durante la competencia , aunque a veces el azar juega un papel fundamental en este tipo de competencias , tenemos el claro ejemplo de argentina que no siempre tuvo las mejores estadísticas pero resulto el vencedor de la competencia .

En cuanto al actuar de los árbitros vemos que la cantidad de tarjetas es mucho más bajo en comparación a las faltas sancionadas por los mismos, y notamos que no hubo casi tarjetas rojas durante la competencia por lo que podemos decir que estábamos en lo correcto .

Al momento de analizar cómo se comportaron los espectadores notamos que no fueron constantes durante la competencia concentrando la mayor parte durante las primeras etapas de la competencia pero de igual forma no hubo una diferencia significativa.